MENGANALISA WILAYAH DAN PROVIDER TAKSI TERBAIK

Sebagai seorang analis untuk sebuah perusahaan berbagi tumpangan (ride-sharing). Ditugaskan untuk menemukan pola pada informasi yang tersedia. Agar didapatkan preferensi penumpang dan dampak faktor eksternal terhadap perjalanan. Analisi data akan dilakukan pada tanggal dan kondisi cuaca tertentu.

Tersedia beberapa data yang harus dipelajari, mulai dari basis data, menganalisis data dari kompetitor, dan menguji hipotesis tentang pengaruh cuaca terhadap frekuensi perjalanan.

Deskripsi Data

Basis data yang memiliki informasi tentang perjalanan taksi di Chicago

Tabel neighborhoods adalah tabel yang memuat wilayah di Kota Chicago

- name: nama wilayah
- neighborhood_id: kode wilayah

Tabel cabs adalah data terkait taksi

- cab_id: kode kendaraan
- vehicle_id: ID teknis kendaraan
- company_name: nama perusahaan yang memiliki kendaraan

Tabel trips adalah tabel yang memuat data terkait perjalanan

- trip_id: kode perjalanan
- cab_id: kode kendaraan yang beroperasi
- start_ts: tanggal dan waktu perjalanan dimulai
- end_ts: tanggal dan waktu perjalanan berakhir
- duration_seconds: durasi perjalanan dalam satuan detik
- distance_miles: jarak perjalanan dalam satuan mil
- pickup_location_id: kode wilayah penjemputan
- dropoff_location_id: kode wilayah pengantaran

Tabel weather_records adalah tabel yang memuat data terkait cuaca

- record_id: kode catatan cuaca
- ts: tanggal dan waktu ketika pencatatan cuaca dilakukan
- temperature: suhu saat pencatatan dilakukan
- description: deskripsi singkat tentang kondisi cuaca

Skema dari empat tabel diatas adalah sebagai berikut:

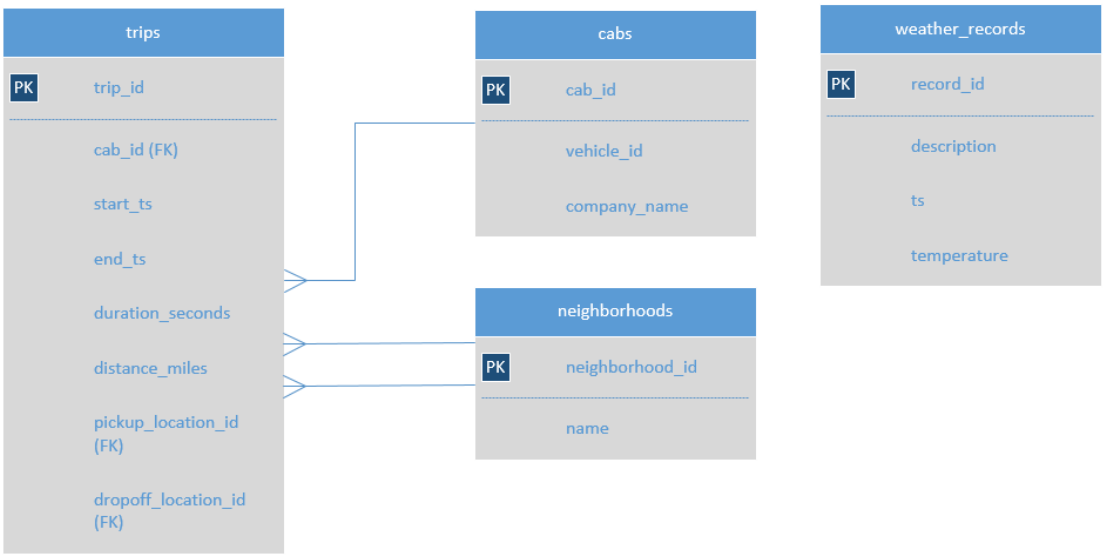

Pemrosesan Data

Dengan menggunakan SQL, akan dilakukan penggabungan dari beberapa tabel yang nantinya akan digunakan untuk melakukan beberapa analisis.

a. Menampilkan kolom company_name. Menemukan jumlah perjalanan taksi untuk setiap perusahaan taksi pada tanggal 15-16 November 2017. Kemudian namakan kolom yang dihasilkan dengan trips_amount dan tampilkan juga kolom tersebut. Hasilnya diurutkan berdasarkan kolom trips_amount dalam urutan menurun.

SQL Code:

```
SELECT
   cabs.company_name,
   COUNT(trips.trip_id) AS trips_amount
FROM
   cabs
   INNER JOIN
   trips
   ON trips.cab_id = cabs.cab_id
WHERE
```

```
    CAST(trips.start_ts AS date) BETWEEN '2017-11-15' AND '2017-11-16'
GROUP BY
    company_name
ORDER BY
    trips_amount DESC;
```

Hasil dari code:

company_name	trips_amount
Flash Cab	19558
Taxi Affiliation Services	11422
Medallion Leasin	10367
Yellow Cab	9888
Taxi Affiliation Service Yellow	9299
Chicago Carriage Cab Corp	9181
City Service	8448
Sun Taxi	7701
Star North Management LLC	7455
Blue Ribbon Taxi Association Inc.	5953
Choice Taxi Association	5015

b. Menemukan jumlah perjalanan untuk setiap perusahaan taksi yang namanya memiliki unsur kata "Yellow" atau "Blue" pada tanggal 1-7 November 2017. Variabel yang dihasilkan diberi nama dengan trips_amount. Hasilnya dikelompokkan berdasarkan kolom company_name.

SQL Code:

```
SELECT
    cabs.company_name AS company_name,
    COUNT(trips.trip_id) AS trips_amount
FROM
    cabs
    INNER JOIN
    trips
    ON trips.cab_id = cabs.cab_id
WHERE
```

```
    CAST(trips.start_ts AS DATE) BETWEEN '2017-11-01' AND '2017-11-07'
    AND cabs.company_name LIKE '%%Yellow%%'
GROUP BY
    company_name
UNION ALL
SELECT
    cabs.company_name as company_name,
    COUNT(trips.trip_id) AS trips_amount
FROM
    cabs
INNER JOIN
    trips
ON
    trips.cab_id = cabs.cab_id
WHERE
    CAST(trips.start_ts AS date) BETWEEN '2017-11-01' AND '2017-11-07'
    AND cabs.company_name LIKE '%%Blue%%'
GROUP BY company_name;
```

Hasil dari code:

company_name	trips_amount
Taxi Affiliation Service Yellow	29213
Yellow Cab	33668
Blue Diamond	6764
Blue Ribbon Taxi Association Inc.	17675

c. Untuk tanggal 1-7 November 2017, perusahaan taksi yang paling populer adalah Flash Cab dan Taxi Affiliation Services. Temukan jumlah perjalanan untuk kedua perusahaan dan namai variabel yang dihasilkan dengan trips_amount serta gabungkan perjalanan dari semua perusahaan lainnya dalam satu kelompok: "Other". Data dikelompokkan berdasarkan nama perusahaan taksi. Beri nama kolom yang memuat nama perusahaan taksi dengan company. Urutan hasil dalam urutan menurun berdasarkan trips_amount.

SQL Code:

```
SELECT
    CASE
        WHEN company_name = 'Flash Cab' THEN 'Flash Cab'
        WHEN company_name = 'Taxi Affiliation Services' THEN 'Taxi Affiliation
Services'
```

```
      ELSE 'Other'
    END AS company,
    COUNT(trips.trip_id) AS trips_amount
FROM
    cabs
INNER JOIN
    trips
ON
    trips.cab_id = cabs.cab_id
WHERE
    CAST(trips.start_ts AS DATE) BETWEEN '2017-11-01' AND '2017-11-07'
GROUP BY
    company
ORDER BY
    trips_amount DESC;
```

Hasil dari code:

company	trips_amount
Other	335771
Flash Cab	64084
Taxi Affiliation Services	37583

d. Mengambil data tentang ID wilayah O'Hare dan Loop dari tabel neighborhoods.
SQL code:

```
SELECT
    *
FROM
    neighborhoods
WHERE name LIKE '%Hare' OR name LIKE 'Loop'
```

Hasil dari code:

neighborhood_id	name
50	Loop
63	O'Hare

e. Untuk setiap jam, akan diambil catatan kondisi cuaca dari tabel weather_records. Dengan menggunakan operator CASE, bagi semua jam menjadi dua kelompok: Bad jika kolom description berisi kata rain atau storm,

dan Good untuk sisanya yang tidak memuat kedua kata tersebut. Kolom yang dihasilkan diberi nama dengan weather_conditions.

SQL code:

```
SELECT
  ts,
  CASE
    WHEN description LIKE '%rain%' OR description LIKE '%storm%' THEN 'Bad'
    ELSE 'Good'
  END AS weather_condition
FROM
  weather_records
```

Hasil dari code:

ts	weather_condition
2017-11-01 00:00:00	Good
2017-11-01 01:00:00	Good
2017-11-01 02:00:00	Good
2017-11-01 03:00:00	Good
2017-11-01 04:00:00	Good
2017-11-01 05:00:00	Good
2017-11-01 06:00:00	Good
2017-11-01 07:00:00	Good
2017-11-01 08:00:00	Good
2017-11-01 09:00:00	Good
2017-11-01 10:00:00	Good

f. Mengambil data dari tabel trips semua perjalanan yang dimulai di Loop (pickup_location_id: 50) pada hari Sabtu dan berakhir di O'Hare (dropoff_location_id: 63). Dapatkan kondisi cuaca untuk setiap perjalanan.

SQL code:

```
SELECT
  start_ts,
  T.weather_conditions,
```

```
  duration_seconds
FROM
  trips
INNER JOIN (
  SELECT
    ts,
    CASE
      WHEN description LIKE '%rain%' OR description LIKE '%storm%' THEN
'Bad'
      ELSE 'Good'
    END AS weather_conditions
  FROM
    weather_records
) T on T.ts = trips.start_ts
WHERE
  pickup_location_id = 50 AND dropoff_location_id = 63 AND EXTRACT (DOW
from trips.start_ts) = 6
ORDER BY trip_id
```

Hasil dari code:

start_ts	weather_conditions	duration_seconds
2017-11-25 12:00:00	Good	1380
2017-11-25 16:00:00	Good	2410
2017-11-25 14:00:00	Good	1920
2017-11-25 12:00:00	Good	1543
2017-11-04 10:00:00	Good	2512
2017-11-11 07:00:00	Good	1440
2017-11-11 04:00:00	Good	1320
2017-11-04 16:00:00	Bad	2969
2017-11-18 11:00:00	Good	2280
2017-11-04 16:00:00	Bad	3120

Pendahuluan:

Setelah selesai melakukan Analisis Data Eksploratif menggunakan SQL, selanjutnya akan melakukannya dengan menggunakan python dan mencari hipotesis durasi perjalanan dari Loop menuju Bandara.

Tujuan dan Tahapan:

Tujuan dari pengolahan data kali ini adalah:

1. Menemukan 10 wilayah teratas untuk pengantaran.
2. Menemukan perusahaan taksi dengan jumlah perjalanan terbanyak.
3. Menguji hipotesis untuk rata-rata perjalanan di wilayah teramai ketika cuaca hujan dan cerah.

Pra-pemrosesan

In [14]:
```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from scipy import stats as st
import numpy as np

import warnings
warnings.filterwarnings('ignore')
```

Melakukan import pada library yang dibutuhkan dalam pengolahan data.

Memuat Data

In [15]:
```
df_company = pd.read_csv('/datasets/project_sql_result_01.csv')
df_location = pd.read_csv('/datasets/project_sql_result_04.csv')
df_weather = pd.read_csv('/datasets/project_sql_result_07.csv')
```

Terdapat tiga buah dataframe yang akan digunakan untuk analisis data eksploratif dan pengujian hipotesis yaitu tabel perusahaan, tabel lokasi drop off, dan tabel cuaca. Ketiga dataframe tersebut akan diobservasi kembali untuk melihat isi datanya apakah sudah sesuai apa belum.

Mengeksplorasi Data Awal Untuk Mendapatkan Informasi Umum

Mengeksplorasi Data Pada Tabel Company

Dalam tabel company, berisi kolom-kolom berikut:

- `company_name`
- `trips_amount`

In [16]:
```
df_company.shape
```

Out[16]:
```
(64, 2)
```

In [17]:
```
df_company.head()
```

Out[17]:

	company_name	trips_amount
0	Flash Cab	19558
1	Taxi Affiliation Services	11422
2	Medallion Leasing	10367
3	Yellow Cab	9888
4	Taxi Affiliation Service Yellow	9299

In [18]:
```
df_company.nunique()
```

Out[18]:
```
company_name    64
trips_amount    56
dtype: int64
```

In [19]:
```
df_company.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 64 entries, 0 to 63
Data columns (total 2 columns):
 #   Column        Non-Null Count  Dtype 
---  ------        --------------  ----- 
 0   company_name  64 non-null     object
 1   trips_amount  64 non-null     int64 
dtypes: int64(1), object(1)
memory usage: 1.1+ KB
```

Dari hasil pengamatan terhadap tabel company tidak ditemukan adanya type dayta yang salah dan data yang null.

Mengeksplorasi Data Pada Tabel Location

Dalam tabel location, berisi kolom-kolom berikut:

- `dropoff_location_name`
- `average_trips`

In [20]:
```
df_location.shape
```

Out[20]:
```
(94, 2)
```

In [21]:
```
df_location.head()
```

Out[21]:

	dropoff_location_name	average_trips
0	Loop	10727.466667
1	River North	9523.666667
2	Streeterville	6664.666667
3	West Loop	5163.666667
4	O'Hare	2546.900000

In [22]:
```
df_location.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 94 entries, 0 to 93
Data columns (total 2 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   dropoff_location_name  94 non-null     object
 1   average_trips          94 non-null     float64
dtypes: float64(1), object(1)
memory usage: 1.6+ KB
```

Dari hasil pengamatan terhadap tabel lokasi drop off tidak ditemukan adanya type dayta yang salah dan data yang null.

Mengeksplorasi Data Pada Tabel Weather

Dalam tabel weather, berisi kolom-kolom berikut:

- `start_ts`
- `weather_condition`
- `duration_seconds`

In [23]:
```
df_weather.shape
```

Out[23]:
```
(1068, 3)
```

In [24]:
```
df_weather.head()
```

Out[24]:

	start_ts	weather_conditions	duration_seconds
0	2017-11-25 16:00:00	Good	2410.0
1	2017-11-25 14:00:00	Good	1920.0
2	2017-11-25 12:00:00	Good	1543.0
3	2017-11-04 10:00:00	Good	2512.0
4	2017-11-11 07:00:00	Good	1440.0

In [25]:
```
df_weather.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1068 entries, 0 to 1067
Data columns (total 3 columns):
 #   Column              Non-Null Count  Dtype  
---  ------              --------------  -----  
 0   start_ts            1068 non-null   object 
 1   weather_conditions  1068 non-null   object 
 2   duration_seconds    1068 non-null   float64
dtypes: float64(1), object(2)
memory usage: 25.2+ KB
```

Terdapat kesalahan pada tipe data di kolom start_ts, yang seharusnya tipe datanya adalah datetime tetapi yang tertera adalah object. Untuk itu akan diubah tipe data menjadi datetime.

In [26]:
```
df_weather['start_ts'] = pd.to_datetime(df_weather['start_ts'])
```

In [27]:
```
df_weather.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1068 entries, 0 to 1067
Data columns (total 3 columns):
 #   Column              Non-Null Count  Dtype         
---  ------              --------------  -----         
 0   start_ts            1068 non-null   datetime64[ns]
 1   weather_conditions  1068 non-null   object        
 2   duration_seconds    1068 non-null   float64       
dtypes: datetime64[ns](1), float64(1), object(1)
memory usage: 25.2+ KB
```

Analisis Data Eksploratif

Mengidentifikasi 10 Wilayah Teratas Yang Dijadikan Sebagai Titik Pengantaran

In [52]:
```
df_avg_trip = df_location.sort_values(['average_trips'], ascending = False).head(10)
df_avg_trip
```

Out[52]:

	dropoff_location_name	average_trips
0	Loop	10727.466667
1	River North	9523.666667
2	Streeterville	6664.666667
3	West Loop	5163.666667
4	O'Hare	2546.900000
5	Lake View	2420.966667
6	Grant Park	2068.533333
7	Museum Campus	1510.000000
8	Gold Coast	1364.233333
9	Sheffield & DePaul	1259.766667

Dari 10 wilayah didapatkan wilayah Loop menjadi yang paling atas sebagai titik pengantaran, sedangakan Sheffield & DePaul beada di urutan terbawah dari list tersebut.

In [49]:
```
sns.barplot(data=df_avg_trip, x='dropoff_location_name', y='average_trips')
plt.show()
```

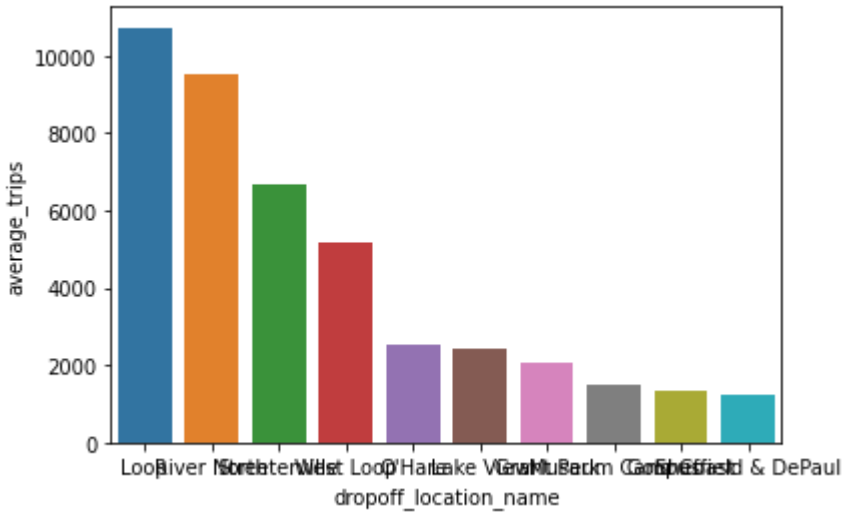

Dari grafik tujuan pengantaran, kita mendapatkan wilayah Loop sebagai yang teratas, diikuti oleh River North, Streeterville, dan West Loop secara berurutan. Keempat wilayah ini sangatlah populer dijadikan tempat tujuan pengantaran, terlihat dari diagram batang bahwa keempat wilayah ini memiliki perbedaan yang cukup signifikan dibandingkan dengan wilayah urutan berikutnya (5 sampai 10). Dimana jika kita mengambil Lake View, wilayah dengan peringkat ke 5, hanya memiliki rata-rata setengahnya dari wilayah di urutan ke 4 yaitu West Loop, ini menandakan bahwa menjadikan 4 wilayah tersebut sebagai tujuan pengantaran sangat berpotensi untuk kedepannya.

Perusahaan Taksi dan Jumlah Perjalanannya

In [51]:
```
df_company
```

Out[51]:

	company_name	trips_amount
0	Flash Cab	19558
1	Taxi Affiliation Services	11422
2	Medallion Leasing	10367
3	Yellow Cab	9888
4	Taxi Affiliation Service Yellow	9299
...	...	...
59	4053 - 40193 Adwar H. Nikola	7
60	2733 - 74600 Benny Jona	7
61	5874 - 73628 Sergey Cab Corp.	5
62	2241 - 44667 - Felman Corp	3
63	3556 - 36214 RC Andrews Cab	2

64 rows × 2 columns

In [50]:
```
sns.barplot(data=df_company, x='company_name', y='trips_amount')
plt.show()
```

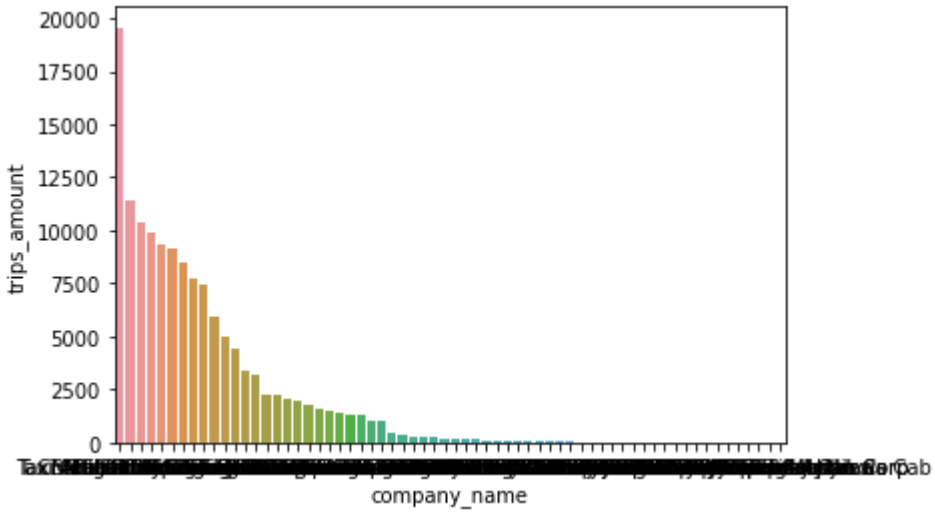

Dari diagram batang yang didapat, perusahaan Flash Cab adalah perusahaan taksi dengan jumlah perjalanan terbanyak, diikuti oleh Taxi Affiliation Services dan Medallion Leasing. Jumlah trip dari Flash Cab juga hampir sebanyak dua kali total trip dari Taxi Affiliation Services maupun Medallion Leasing. Kemungkinan Flash Cab adalah perusahaan taksi yang memiliki daerah pengantaran ke wilayah Loop, River North, Streeterville, atau West Loop yang paling banyak sehingga mereka bisa menjadi yang teratas dari jumlah trips jika dibandingkan dengan perusahaan taksi lainnya.

Menguji Hipotesis

Hipotesis yang diuji berada pada kondisi dimana hari adalah Sabtu dan kondisi cuaca hujan. Untuk itu kita harus memastikan bahwa tanggal pada kolom start_ts menunjukkan hari sabtu dan memisahkan data antara Good atau Bad.

In [31]:
```
df_weather['day_trip'] = df_weather['start_ts'].dt.strftime('%A')
```

In [32]:
```
df_weather
```

Out[32]:

	start_ts	weather_conditions	duration_seconds	day_trip
0	2017-11-25 16:00:00	Good	2410.0	Saturday
1	2017-11-25 14:00:00	Good	1920.0	Saturday
2	2017-11-25 12:00:00	Good	1543.0	Saturday
3	2017-11-04 10:00:00	Good	2512.0	Saturday
4	2017-11-11 07:00:00	Good	1440.0	Saturday
...	...	...	...	...
1063	2017-11-25 11:00:00	Good	0.0	Saturday
1064	2017-11-11 10:00:00	Good	1318.0	Saturday
1065	2017-11-11 13:00:00	Good	2100.0	Saturday
1066	2017-11-11 08:00:00	Good	1380.0	Saturday
1067	2017-11-04 16:00:00	Bad	2834.0	Saturday

1068 rows × 4 columns

In [33]:
```
df_weather['day_trip'].unique()
```

Out[33]:
```
array(['Saturday'], dtype=object)
```

Kolom day_trip hanya memiliki satu nilai unik yaitu saturday dimana ini berarti keseluruhan data ada kolom memang terjadi di hari Sabtu.

In [34]:
```
df_weather['weather_conditions'].unique()
```

Out[34]:
```
array(['Good', 'Bad'], dtype=object)
```

Kolom weather_conditions hanya berisi dua nilai unik, yaitu Good dan Bad. Untuk itu kita akan memisahkan kedua variabel tersebut.

In [35]:
```
df_rain = df_weather[df_weather['weather_conditions'] == 'Bad'].reset_index(drop=True)
df_rain
```

Out[35]:

	start_ts	weather_conditions	duration_seconds	day_trip
0	2017-11-04 16:00:00	Bad	2969.0	Saturday
1	2017-11-18 12:00:00	Bad	1980.0	Saturday
2	2017-11-04 17:00:00	Bad	2460.0	Saturday
3	2017-11-04 16:00:00	Bad	2760.0	Saturday
4	2017-11-18 12:00:00	Bad	2460.0	Saturday
...	...	...	...	...
175	2017-11-18 12:00:00	Bad	2560.0	Saturday
176	2017-11-18 10:00:00	Bad	1908.0	Saturday
177	2017-11-18 12:00:00	Bad	2400.0	Saturday
178	2017-11-18 16:00:00	Bad	2186.0	Saturday
179	2017-11-04 16:00:00	Bad	2834.0	Saturday

180 rows × 4 columns

In [36]:
```
df_clear = df_weather[df_weather['weather_conditions'] == 'Good'].reset_index(drop=Tru
df_clear
```

Out[36]:

	start_ts	weather_conditions	duration_seconds	day_trip
0	2017-11-25 16:00:00	Good	2410.0	Saturday
1	2017-11-25 14:00:00	Good	1920.0	Saturday
2	2017-11-25 12:00:00	Good	1543.0	Saturday
3	2017-11-04 10:00:00	Good	2512.0	Saturday
4	2017-11-11 07:00:00	Good	1440.0	Saturday
...	...	...	...	...
883	2017-11-11 06:00:00	Good	1500.0	Saturday
884	2017-11-25 11:00:00	Good	0.0	Saturday
885	2017-11-11 10:00:00	Good	1318.0	Saturday
886	2017-11-11 13:00:00	Good	2100.0	Saturday
887	2017-11-11 08:00:00	Good	1380.0	Saturday

888 rows × 4 columns

- H0 = Rata-rata durasi perjalanan pada Sabtu dengan kondisi hujan dan cerah adalah SAMA
- H1 = Rata-rata durasi perjalanan pada Sabtu dengan kondisi hujan dan cerah adalah TIDAK SAMA

Kedua hipotesis menggunakan alpha = 0.05, agar tingkat kepercayaan dari pengujian hipotesis sebesar 95% (100 *(1-alpha) %).

In [37]:
```
np.var(df_rain['duration_seconds']), np.var(df_clear['duration_seconds'])
```

Out[37]:
```
(517403.56330246915, 575732.9308497686)
```

In [38]:
```
df_rain['duration_seconds'].describe(), df_clear['duration_seconds'].describe()
```

Out[38]:
```
(count     180.000000
 mean     2427.205556
 std       721.314138
 min       480.000000
 25%      1962.000000
 50%      2540.000000
 75%      2928.000000
 max      4980.000000
 Name: duration_seconds, dtype: float64,
 count     888.000000
 mean     1999.675676
 std       759.198268
 min         0.000000
 25%      1389.750000
 50%      1800.000000
 75%      2460.000000
 max      7440.000000
 Name: duration_seconds, dtype: float64)
```

Rata-rata yang didapat dengan menggunakan metode describe terlihat cukup berbeda jauh dimana durasi rata-rata ketika cuaca hujan 2427.205556 dan ketika cuaca cerah 1999.675676.

In [39]:
```
(np.var(df_clear['duration_seconds']) - np.var(df_rain['duration_seconds'])) / np.var(
```

Out[39]:
```
0.11273476196220286
```

In [40]:
```
alpha = 0.05

results = st.ttest_ind(df_clear['duration_seconds'], df_rain['duration_seconds'], equa

print('p-value= ', results.pvalue)

if results.pvalue < alpha:
    print('Kita menolak hipotesis nol')
else:
    print('Kita menerima hipotesis nol')
```

```
p-value=  6.517970327099473e-12
Kita menolak hipotesis nol
```

Dengan menggunakan T-test independent (Levene's Method), didapatkan p-value sebesar 6.517970327099473e-12, dengan kata lain p-value < alpha. Mengacu dengan hasil itu kita menolak Hipotesis Null dimana rata-rata durasi perjalanan pada Sabtu dengan kondisi hujan dan cerah sama.

Kesimpulan

Dari hasil pengolahan data, didapatkan kesimpulan:

- Wilayah Loop mendaji wilayah teratas untuk tujuan pengantaran, diikuti oleh River North, Streeterville, dan West Loop secara berurutan.
- Flash Cab menjadi perusahaan taksi dengan jumlah pengantaran terbanyak dibandingkan dengan taksi lainnya. Flash Cab memiliki total perjalanan hampir dua kali lebih banyak daripada perusahaan taksi yang berada di peringkat kedua yaitu Taxi Affiliation Services. Kemungkinan Flash Cab menjadi perusahaan taksi yang memiliki banyak tujuan pengantaran di 4 wilayah teratas yaitu Loop, River North, Streeterville, dan West Loop
- Hasil hipotesis untuk rata-rata durasi perjalanan ketika hujan dengan cerah adalah tidak sama, karena kita bisa melihat adanya perbedaan rata-rata durasi perjalanan yang cukup signifikan dan hasil dari t-test menunjukkan nilai p value sebesar 6.517970327099473e-12